肌少症骨架偵測系統

圖表分析報告

以 MediaPipe 骨架資料與圖神經網路，自動化 AWGS 2019 體能表現評估

受試者 31 人（肌少症 12 人 / 無肌少症 19 人） · 動作樣本 92 筆

評估方式：5-fold 交叉驗證，以受試者分組，全數採 out-of-fold 預測

本報告為可行性研究成果，非經臨床驗證之醫療器材。
所有評估結果僅供篩檢參考，不可取代專業醫療診斷。

產出日期：2026-08-24

目錄

一、資料理解　先看清楚手上的資料長什麼樣、有什麼限制

圖 01　骨架關鍵點定義
圖 02　三項檢測動作
圖 03　年齡是最大的干擾因子
圖 04　錄影品質稽核
圖 05　動作長度分布

二、特徵與可分性　資料裡究竟有沒有可用的訊號？

圖 06　臨床運動學指標
圖 07　特徵判別力排行
圖 08　手工特徵的二維投影
圖 09　ST-GCN 特徵的二維投影
圖 10　out-of-fold 預測空間

三、模型與結果　模型怎麼做判斷，做得如何

圖 11　分類器架構
圖 12　ROC 曲線
圖 13　Precision-Recall 曲線
圖 14　混淆矩陣與門檻取捨
圖 15　合成資料預訓練的效果
圖 16　動作組合消融
圖 17　逐人預測與錯誤案例

四、總結　整體流程與必須誠實說明的限制

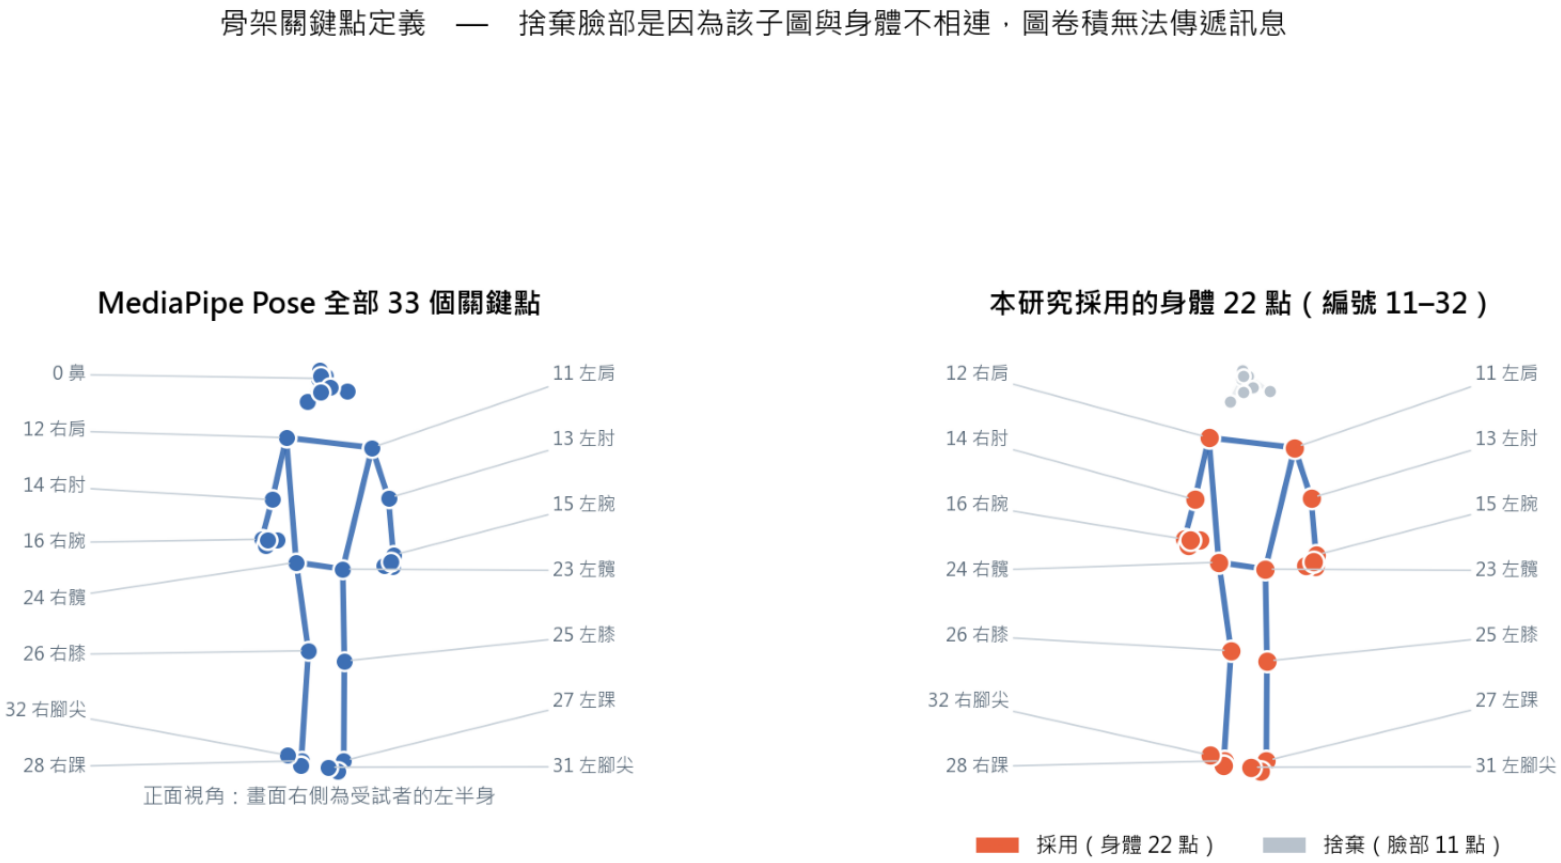
建議給醫療人員閱讀的四張：圖 18（系統流程）、圖 03（年齡混淆）、圖 04（資料品質）、圖 20（半蹲維持期）

圖 18　系統整體流程
圖 19　信賴區間比較
圖 20　半蹲：臨床協定決定了該測量什麼
圖 21　三系統比較

一、資料理解

先看清楚手上的資料長什麼樣、有什麼限制

圖 01　骨架關鍵點定義

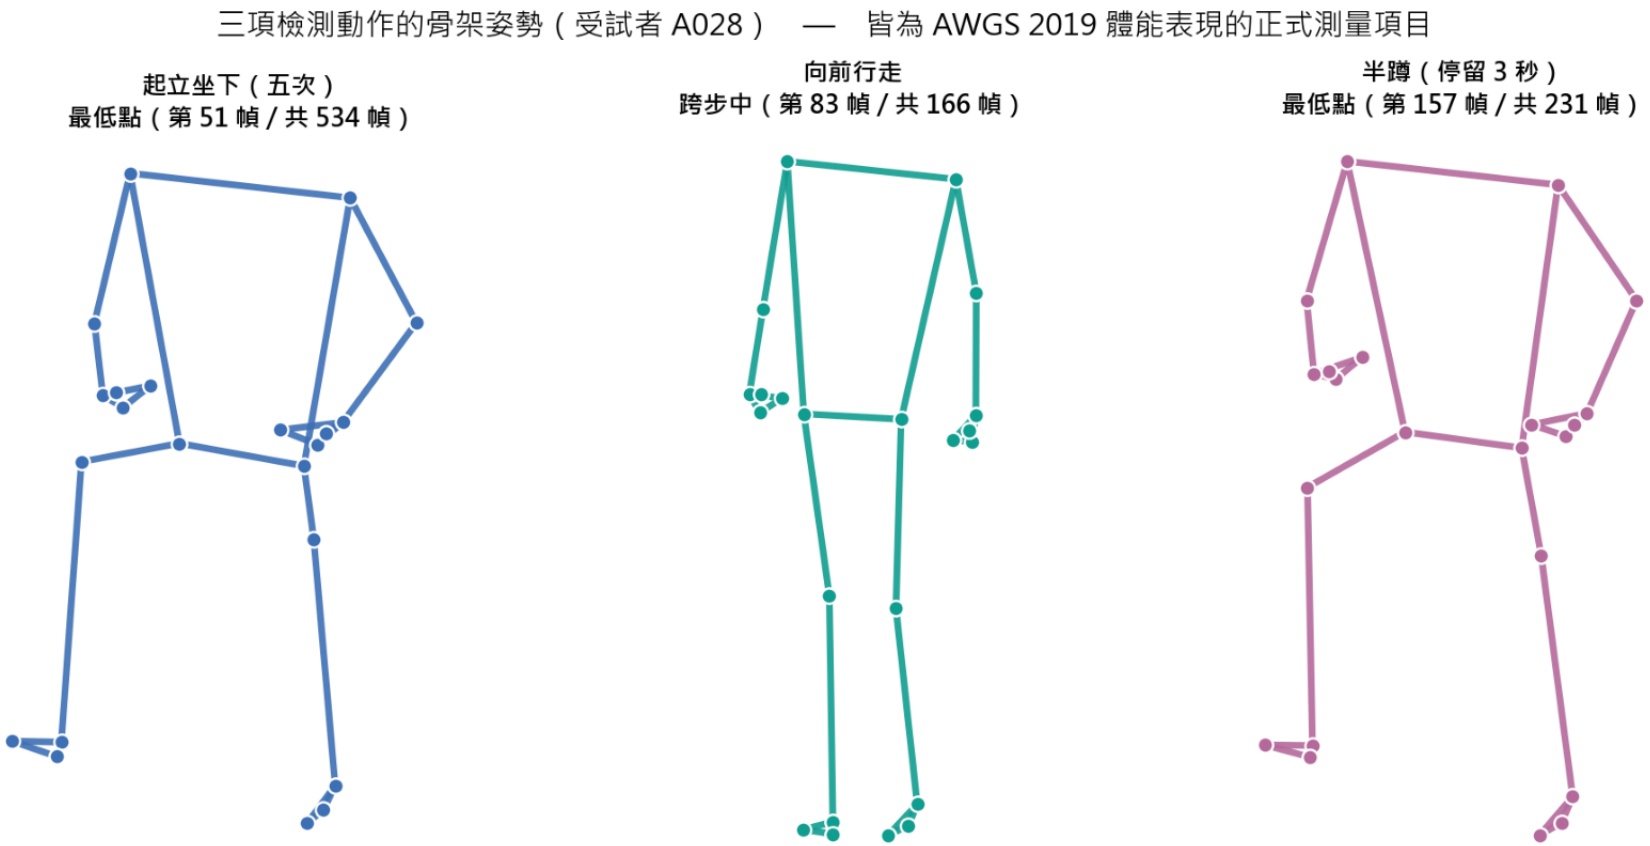


說明

MediaPipe Pose 對每一幀影像輸出 33 個關鍵點。本研究只採用身體的 22 點（編號 11–32），捨棄臉部的 11 點。

捨棄的原因不是臉部不重要，而是在 MediaPipe 的官方骨架連線定義中，臉部與身體並不相連。圖神經網路依靠關節之間的「連線」傳遞資訊，不相連的部位會讓整張圖分裂成三塊互不相通的子圖，臉部的資訊永遠無法傳到身體，反而成為雜訊。

圖 02　三項檢測動作

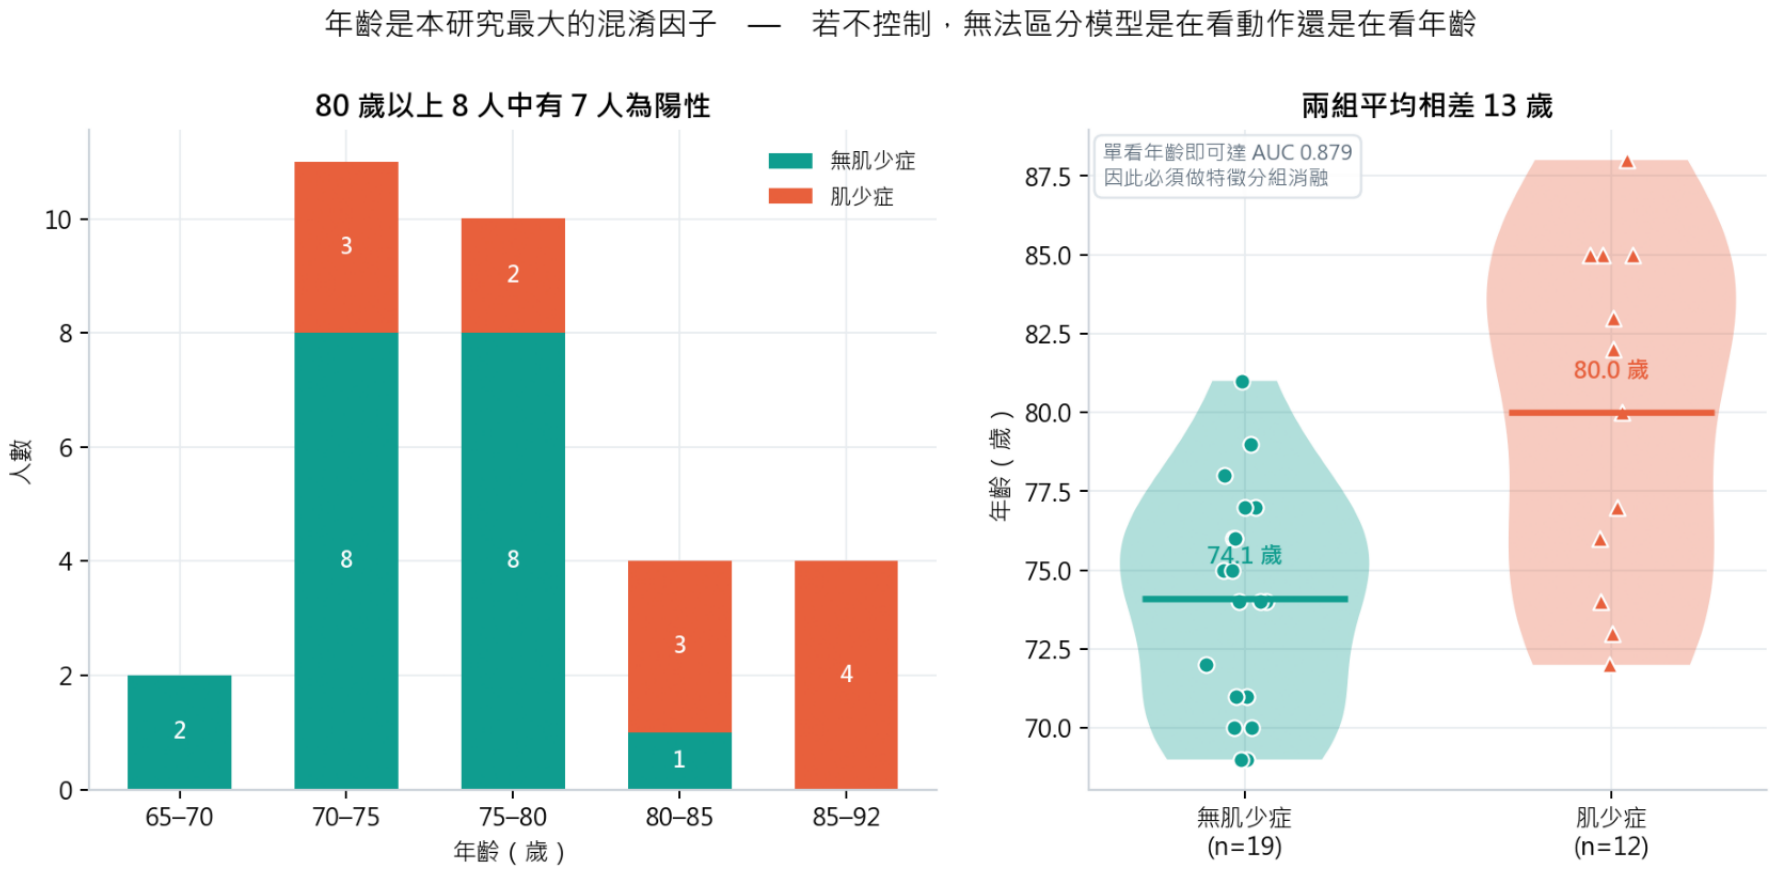


說明

起立坐下、向前行走、半蹲。三者皆為 AWGS 2019（亞洲肌少症工作小組）診斷準則中「體能表現」的正式測量項目。

本系統要做的，是把原本需要治療師拿碼錶手動計時的項目自動化。

圖 03　年齡是最大的干擾因子



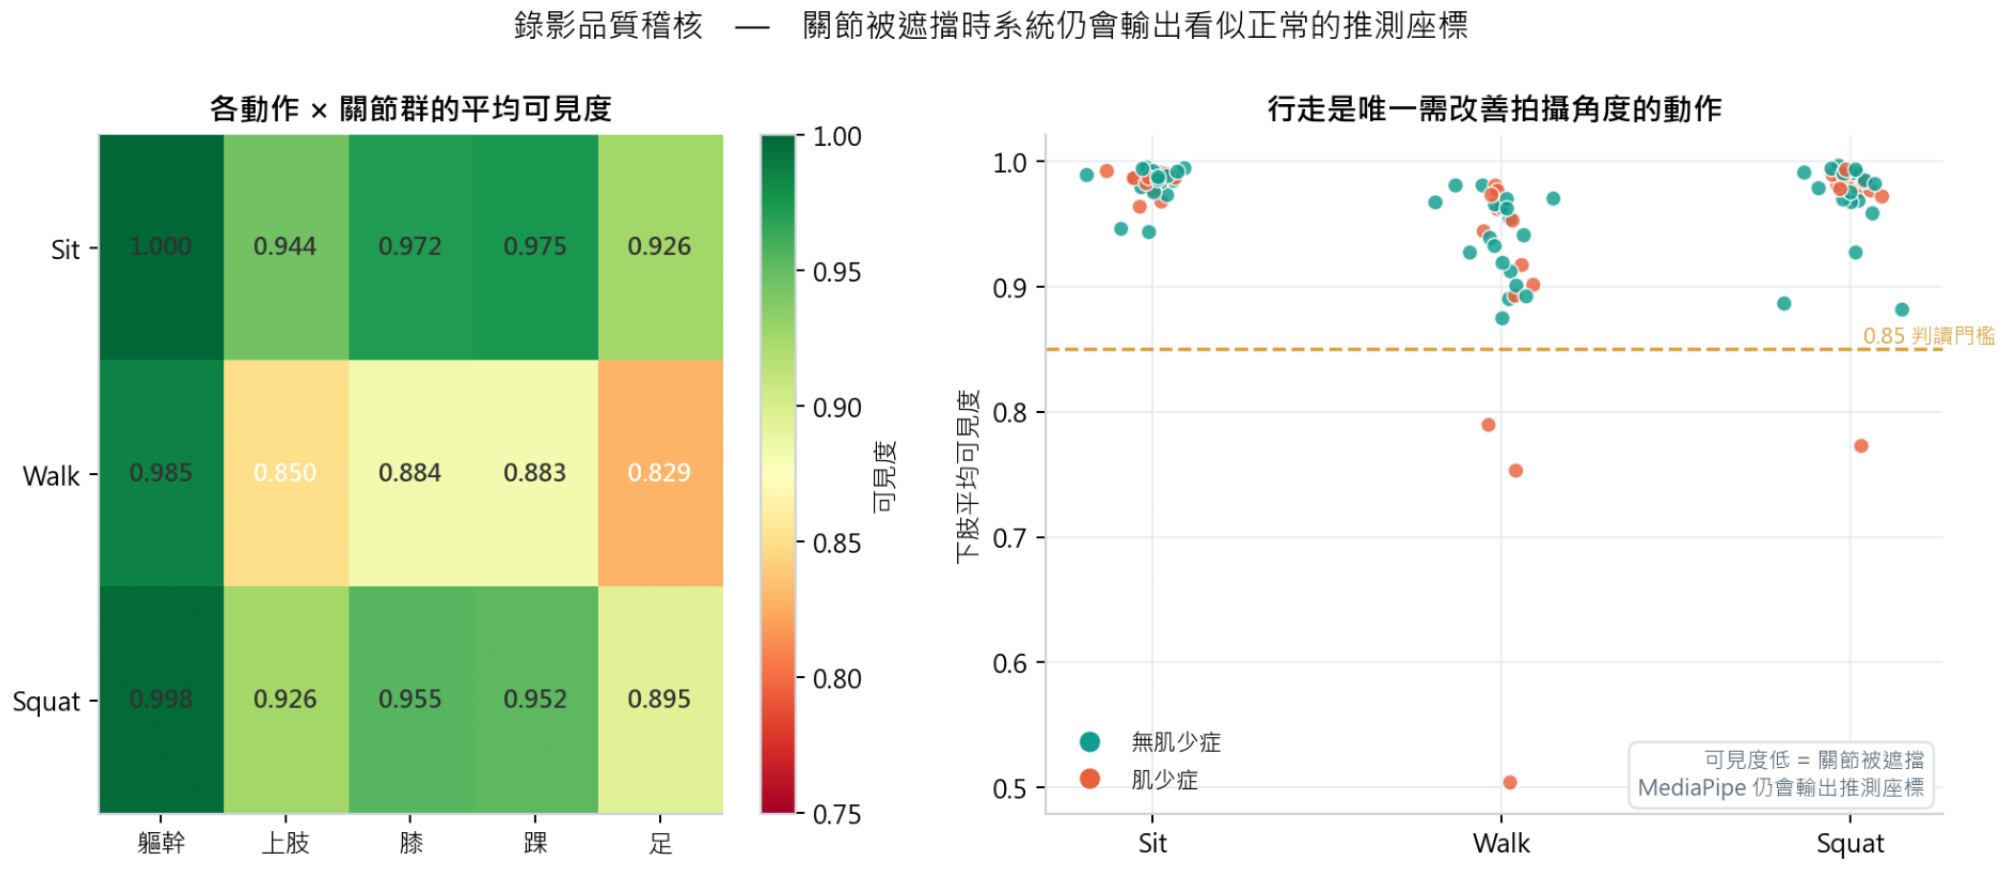
說明

肌少症組的平均年齡比對照組大 13 歲（80.0 歲 vs 74.1 歲），80 歲以上的 8 人中有 7 人為陽性。

這代表「只看年齡」不做任何動作分析，判別力就已經達到 AUC 0.879。因此本研究的所有結果都必須拆成三種對照：
只看年齡、只看動作、兩者合併，否則無法分辨模型究竟是在分析動作，還是只是在看年齡。

建議後續收案優先補收：80 歲以上的健康長者、75 歲以下的肌少症患者。

圖 04　錄影品質稽核



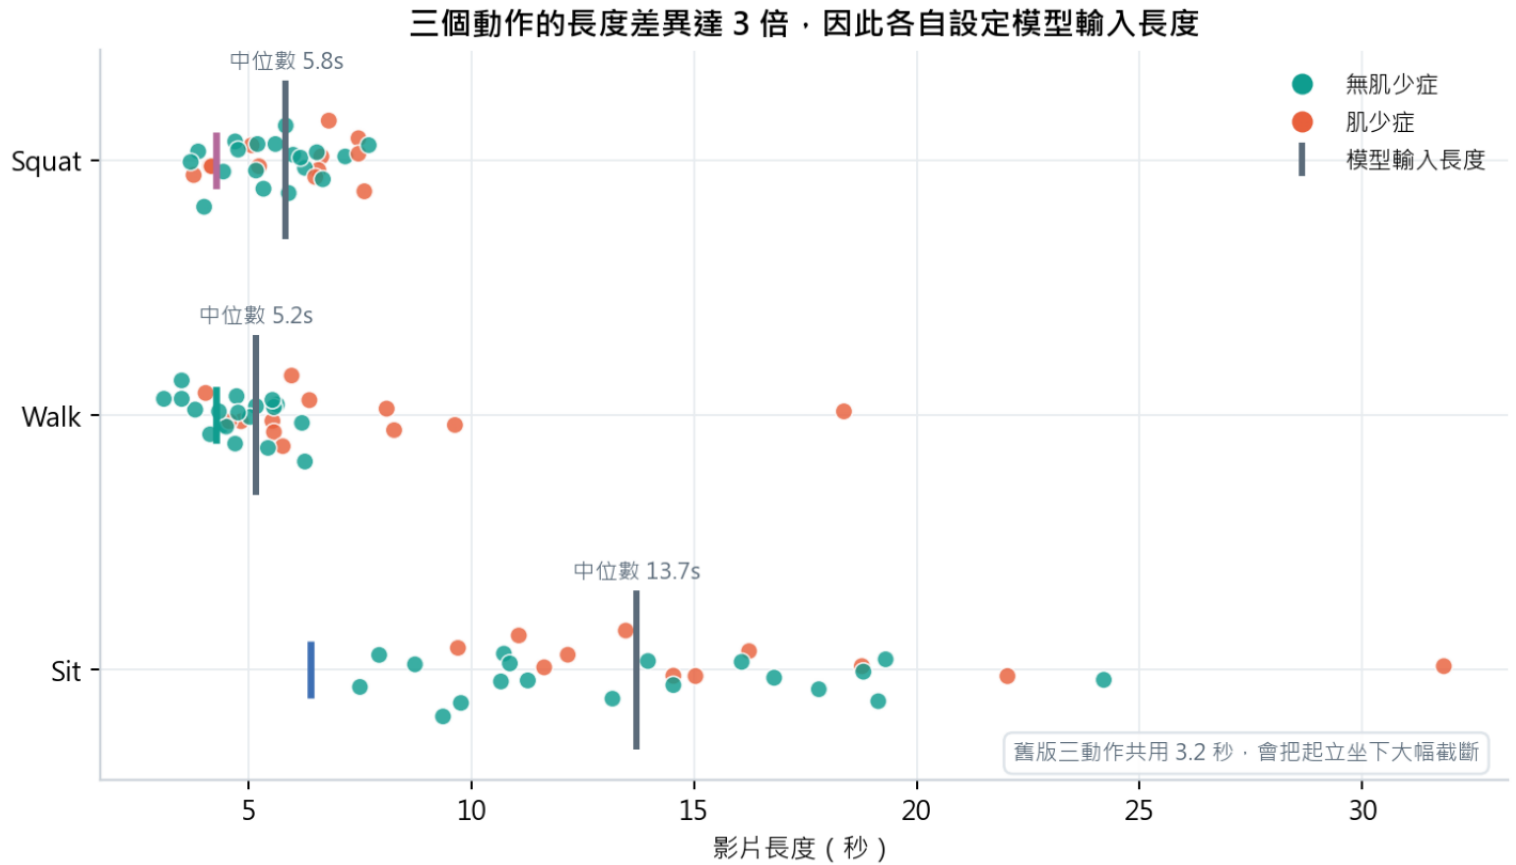
說明

MediaPipe 在關節被遮擋時，仍會「推測」並輸出一組外觀完全正常的座標，因此低品質的資料從數值上看不出異常。

三項動作中，只有行走的下肢可見度偏低（0.916，遮擋幀佔 7.7%），個別樣本更低至 0.504。原因是側面拍攝時，靠鏡頭側的肢體會遮住另一側。

建議：行走改以斜前方 45 度拍攝，或加設第二機位。此項改善對資料品質的效益高於單純增加收案人數。

圖 05　動作長度分布



說明

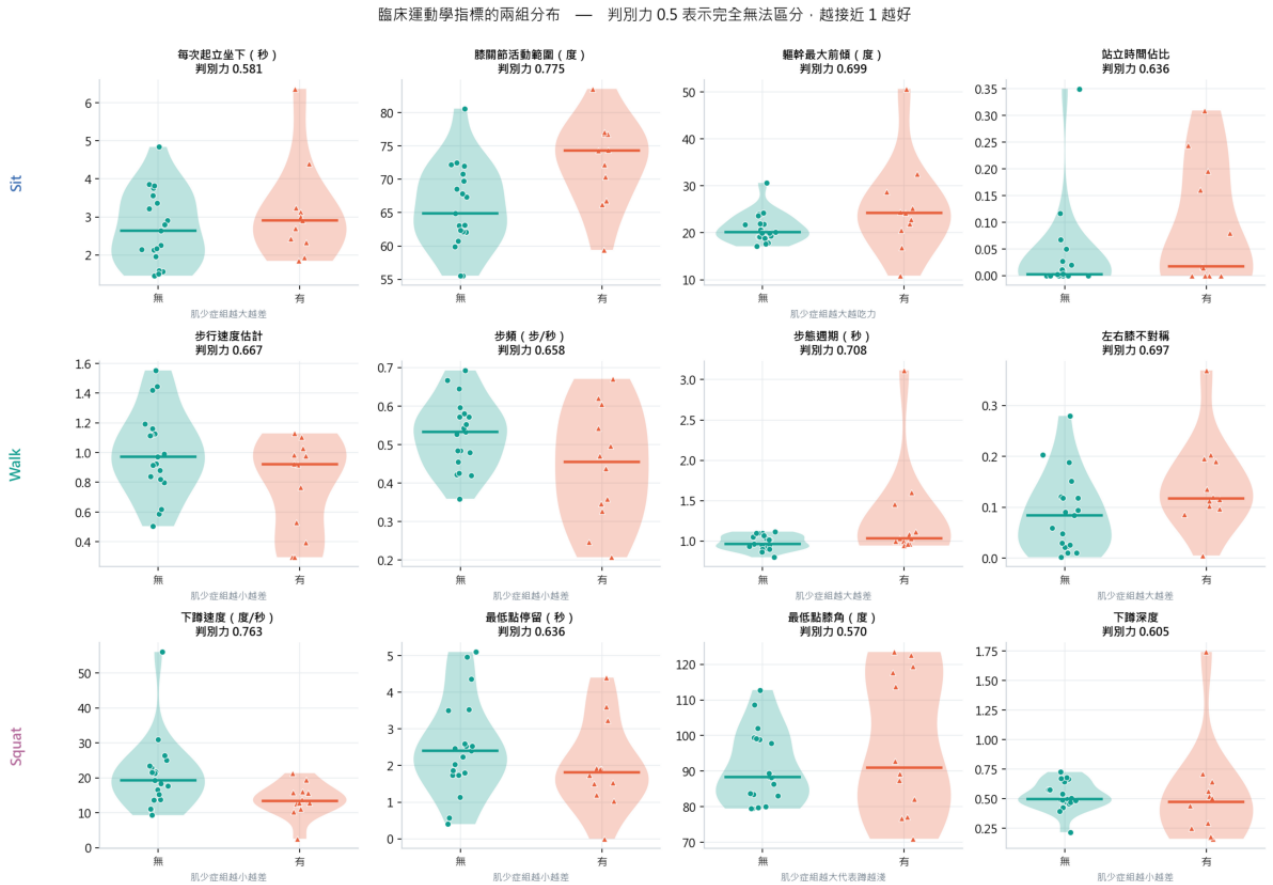
三個動作的長度差距達 3 倍（起立坐下中位數 14 秒、行走 5 秒、半蹲 6 秒），因此模型的輸入長度必須各自設定。

早期版本三個動作共用 3.2 秒的輸入長度，會把 14 秒的起立坐下大幅截斷。

二、特徵與可分性

資料裡究竟有沒有可用的訊號？

圖 06　臨床運動學指標

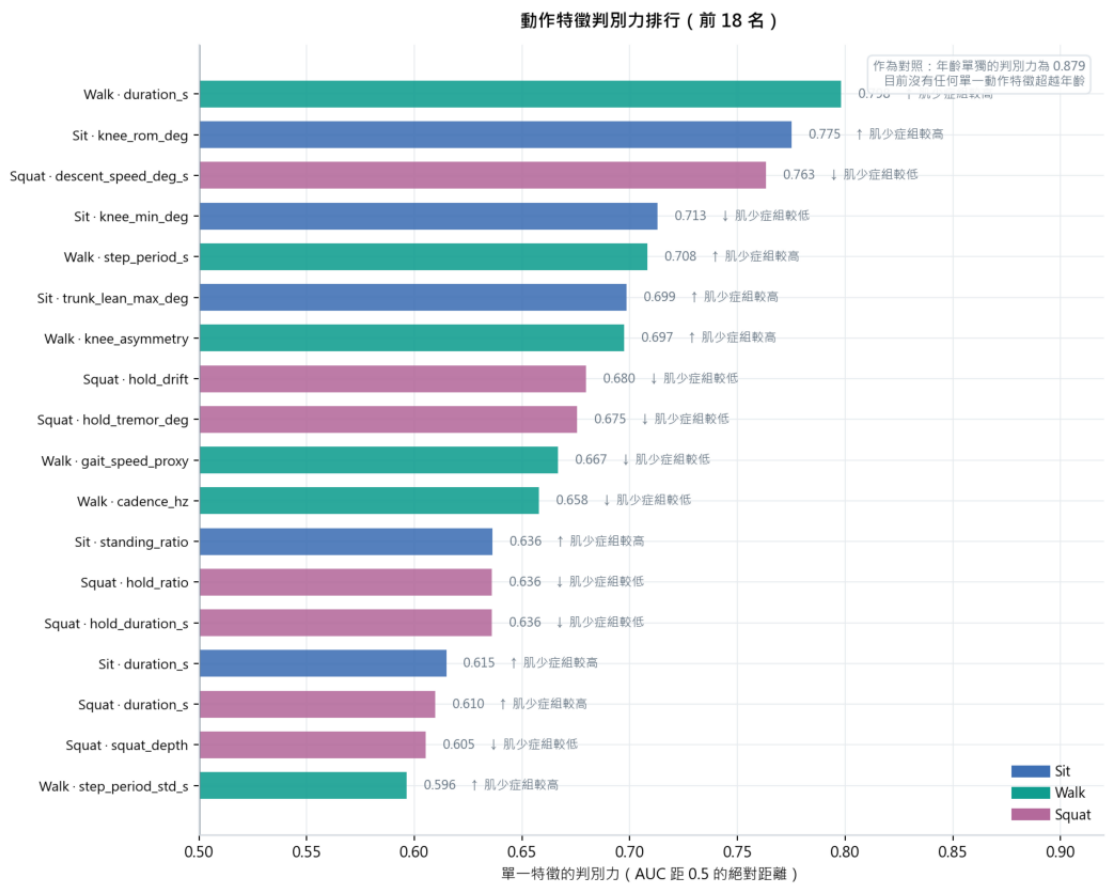


說明

由骨架資料自動計算的臨床指標，在兩組間的分布。「判別力」為 AUC 距 0.5 的距離：0.5 表示完全無法區分，越接近 1 越好。

行走的多項指標（步速、步頻、步態週期）方向一致地指向「肌少症組走得較慢」，與 AWGS 2019 以步速為核心診斷條件相符。

圖 07　特徵判別力排行

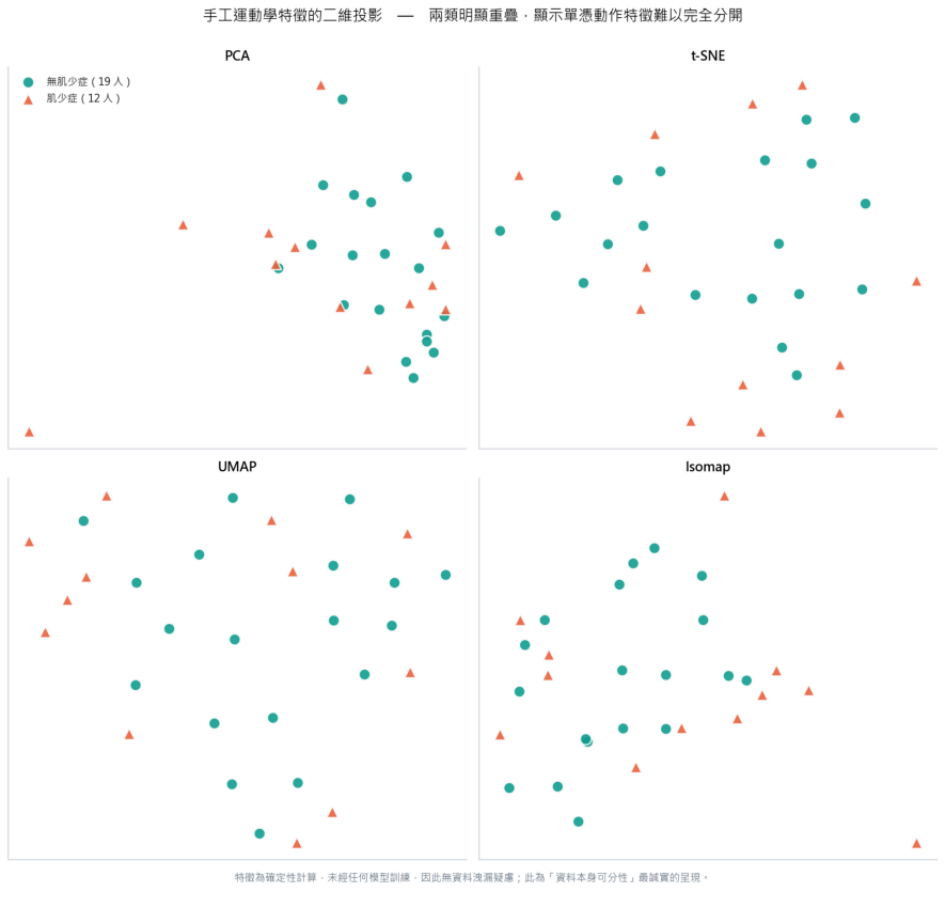


說明

所有動作特徵的判別力排序。最強者為行走耗時（0.798）。

作為對照：年齡單獨的判別力為 0.879。目前沒有任何單一動作特徵能超越年齡。

圖 08　手工特徵的二維投影



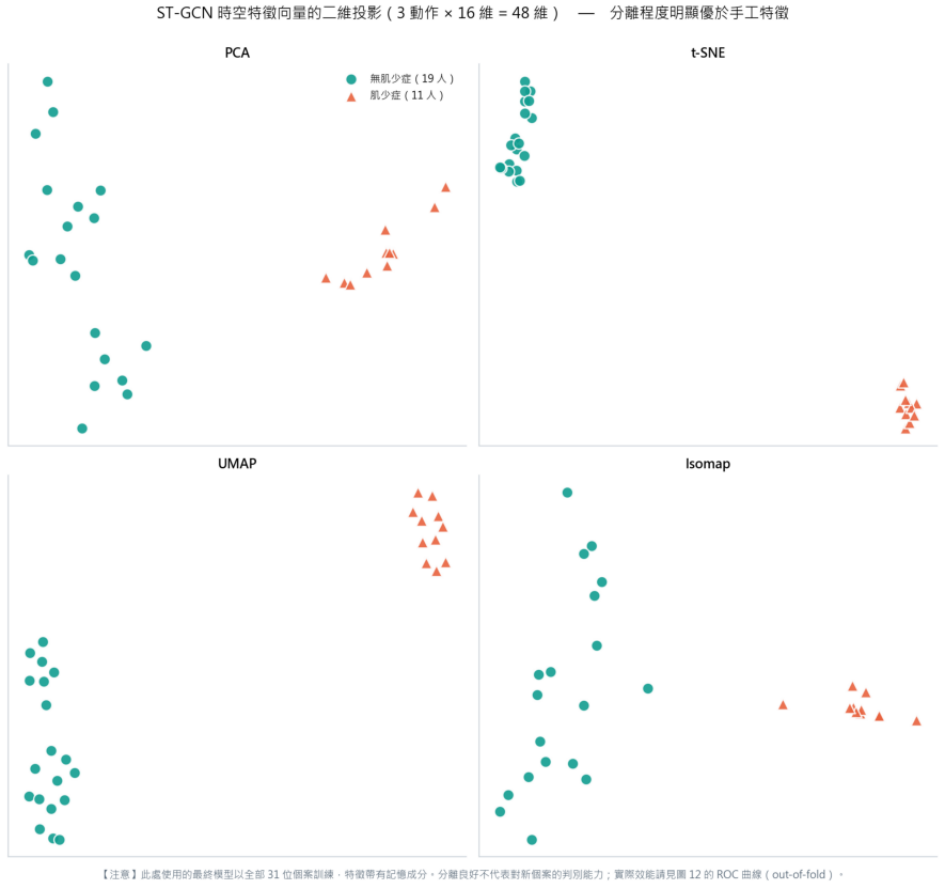
說明

以四種降維方法（PCA、t-SNE、UMAP、Isomap）把多維特徵壓縮到平面上觀察。

兩類明顯重疊，代表單憑這些人工設計的動作指標難以完全區分兩組。

這張圖的可信度最高——特徵為確定性的數學計算，未經任何模型訓練，因此不存在資料洩漏的疑慮，是「資料本身可分性」最誠實的呈現。

圖 09　ST-GCN 特徵的二維投影



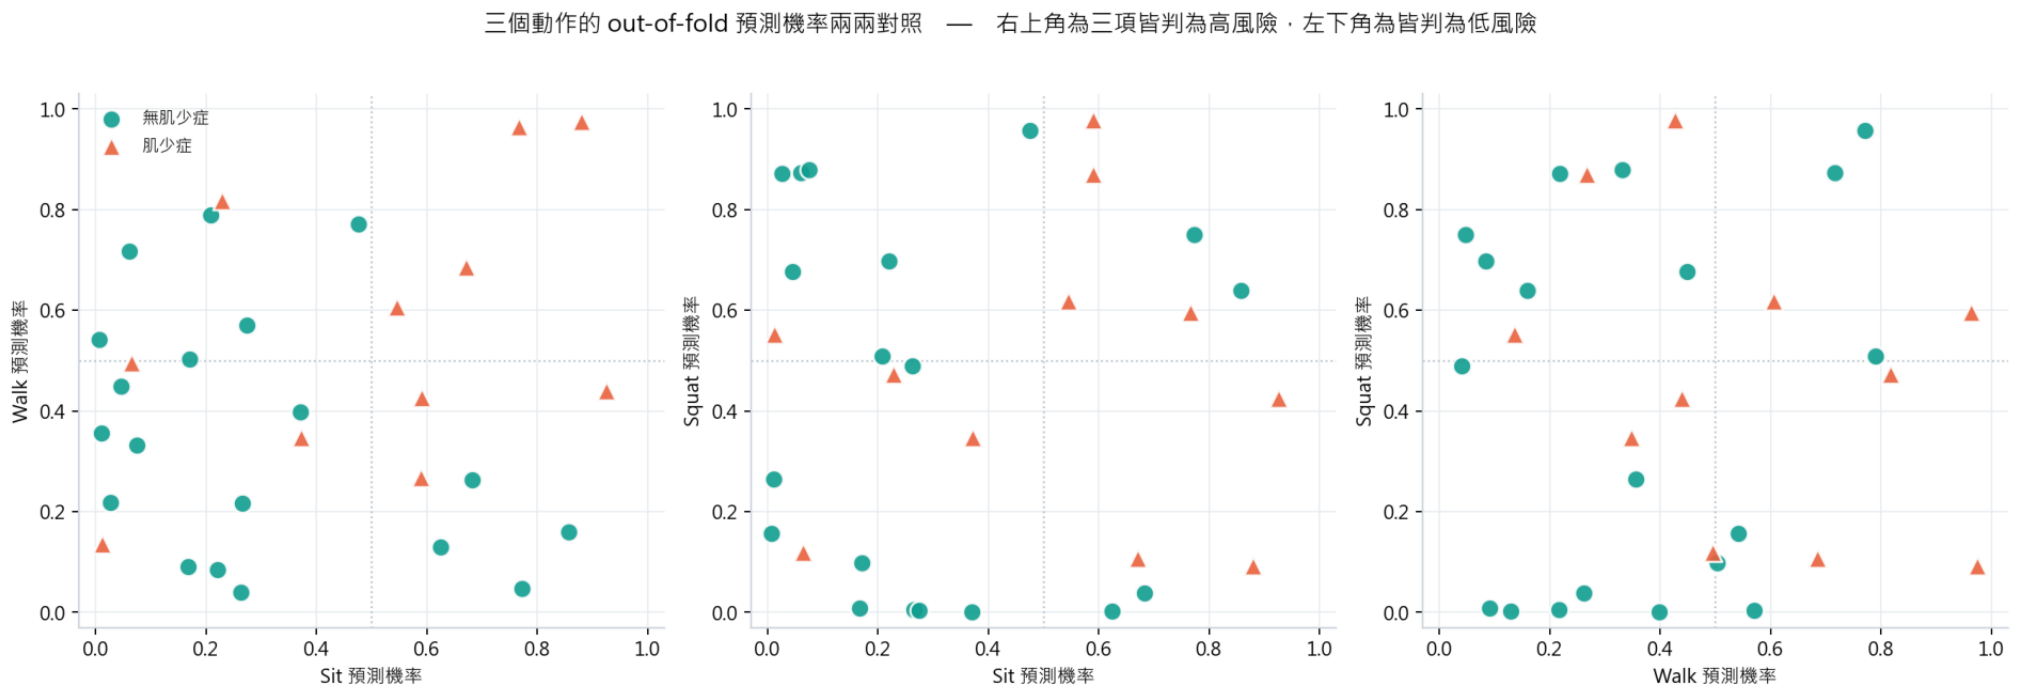
說明

ST-GCN 學到的時空特徵向量（3 動作 × 16 維 = 48 維）的二維投影。

注意：分離良好不代表判別能力。此圖使用的最終模型是以全部 31 位個案訓練的，模型已經「看過」這些人，特徵帶有記憶成分。分得開是理所當然的結果。

若要說明模型的真實效能，請引用 ROC 曲線（下一章），而非此圖。

圖 10　out-of-fold 預測空間



說明

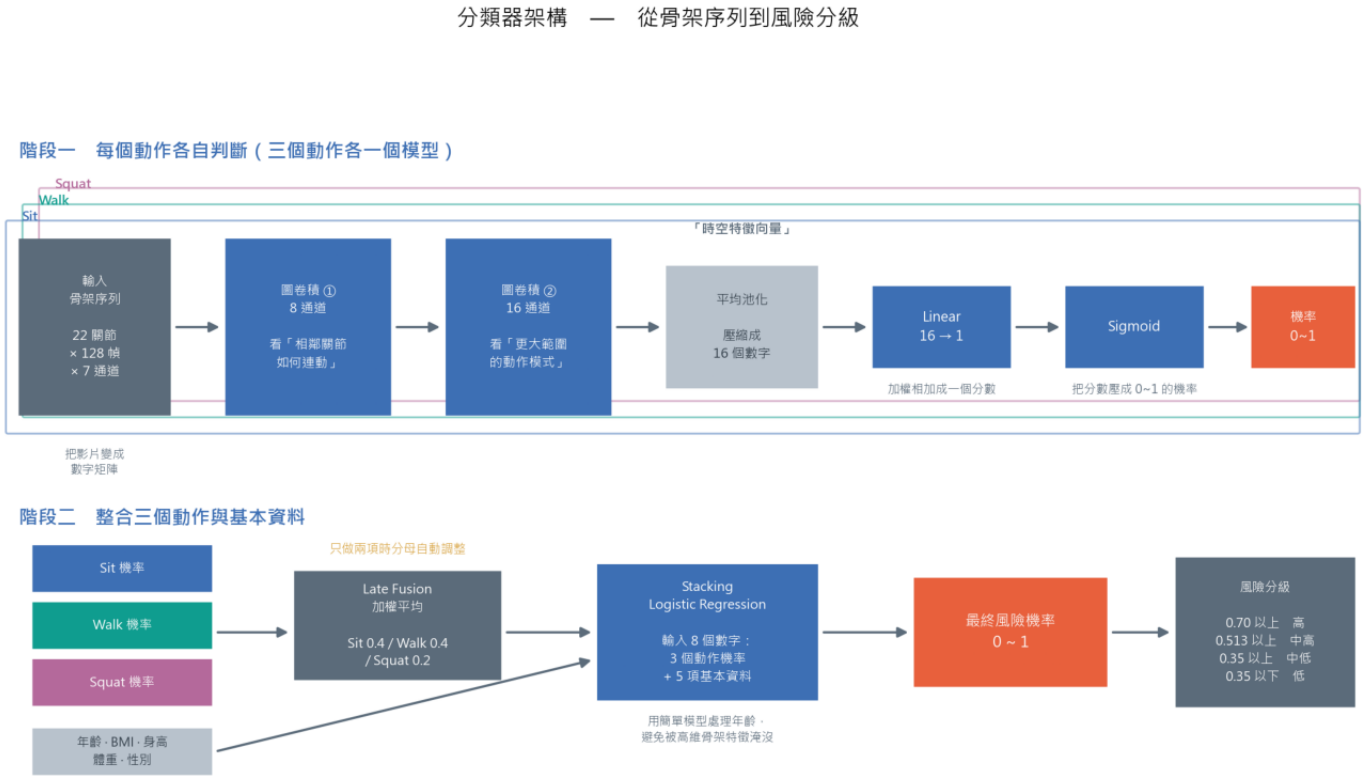
三個動作的預測機率兩兩對照。每個人的預測值都來自「沒有看過他」的模型，因此不含記憶成分，反映真實的判別情形。

右上角為三項動作皆判為高風險，左下角為皆判為低風險。

三、模型與結果

模型怎麼做判斷，做得如何

圖 11　分類器架構



說明

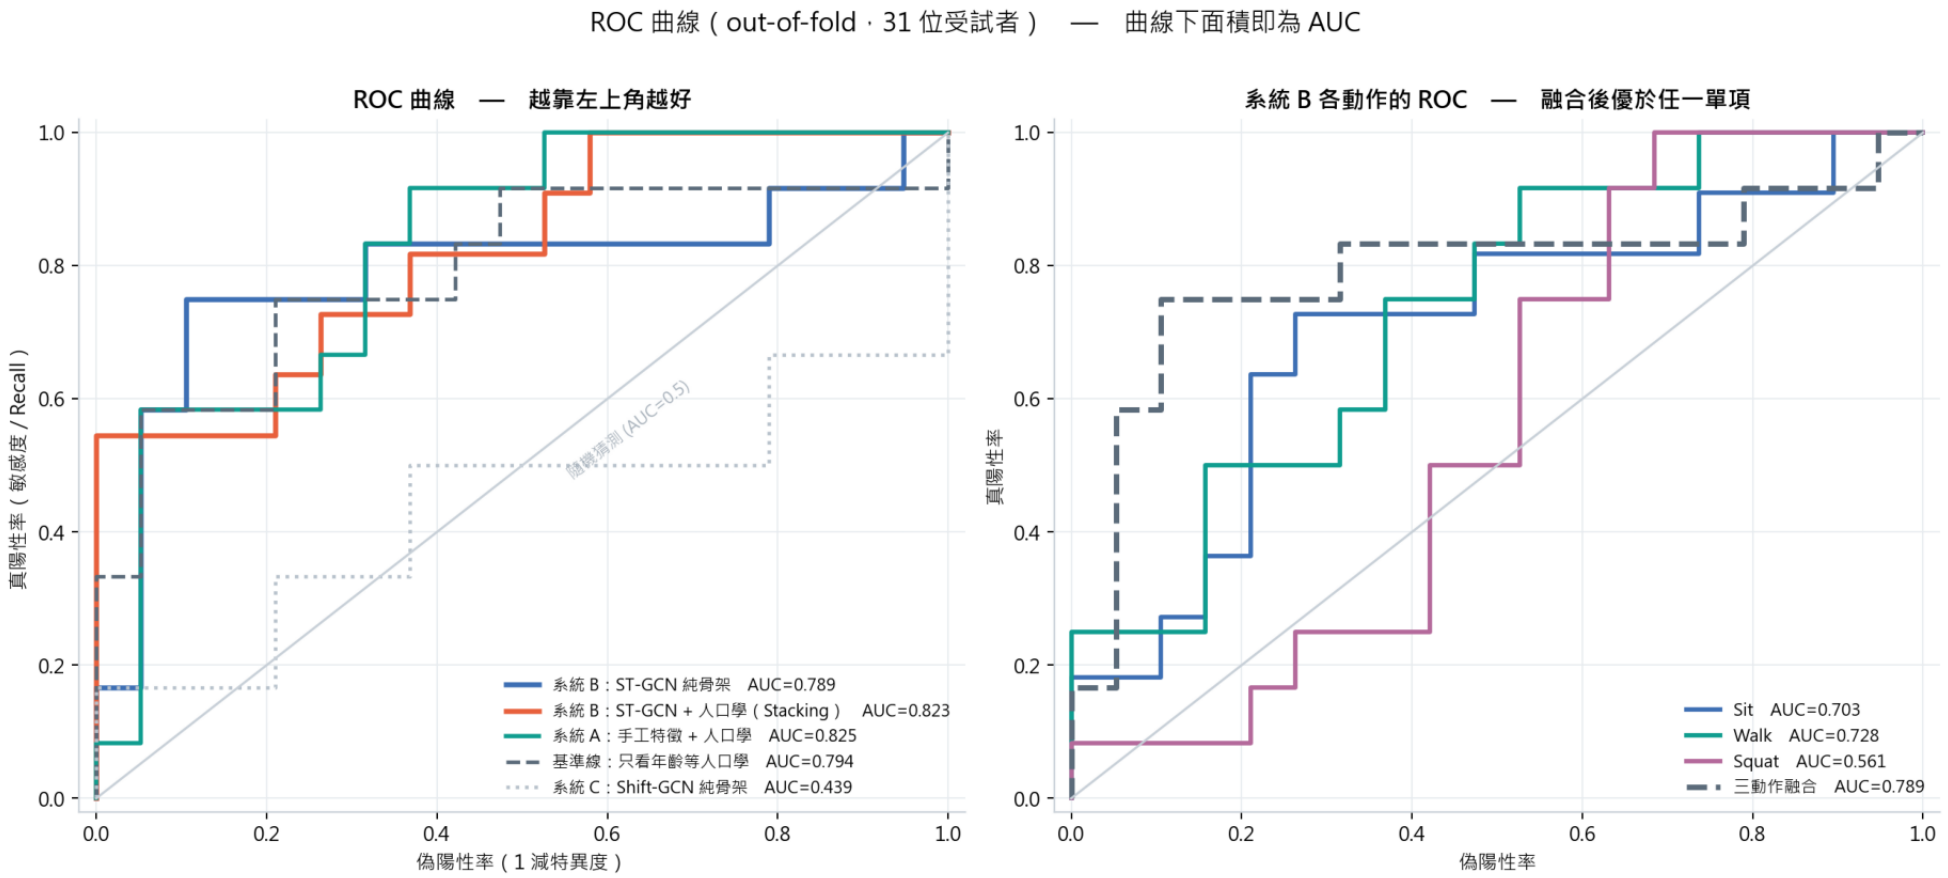
分為兩階段：

階段一——三個動作各有一個獨立的 ST-GCN 模型。骨架序列經過兩層圖卷積後，壓縮成 16 個數字（時空特徵向量），再由 Linear 層加權相加成一個分數，最後以 Sigmoid 壓成 0~1 的機率。

階段二——三個動作的機率先加權平均（Late Fusion），再與年齡等基本資料一起交給 Logistic Regression 做最終判斷。

分成兩階段的原因：若把骨架特徵與年齡丟進同一個網路聯合訓練，16 維的骨架特徵會讓模型有足夠自由度去「背下」訓練樣本，反而學不到「年齡越大風險越高」這種簡單關係。

圖 12　ROC 曲線



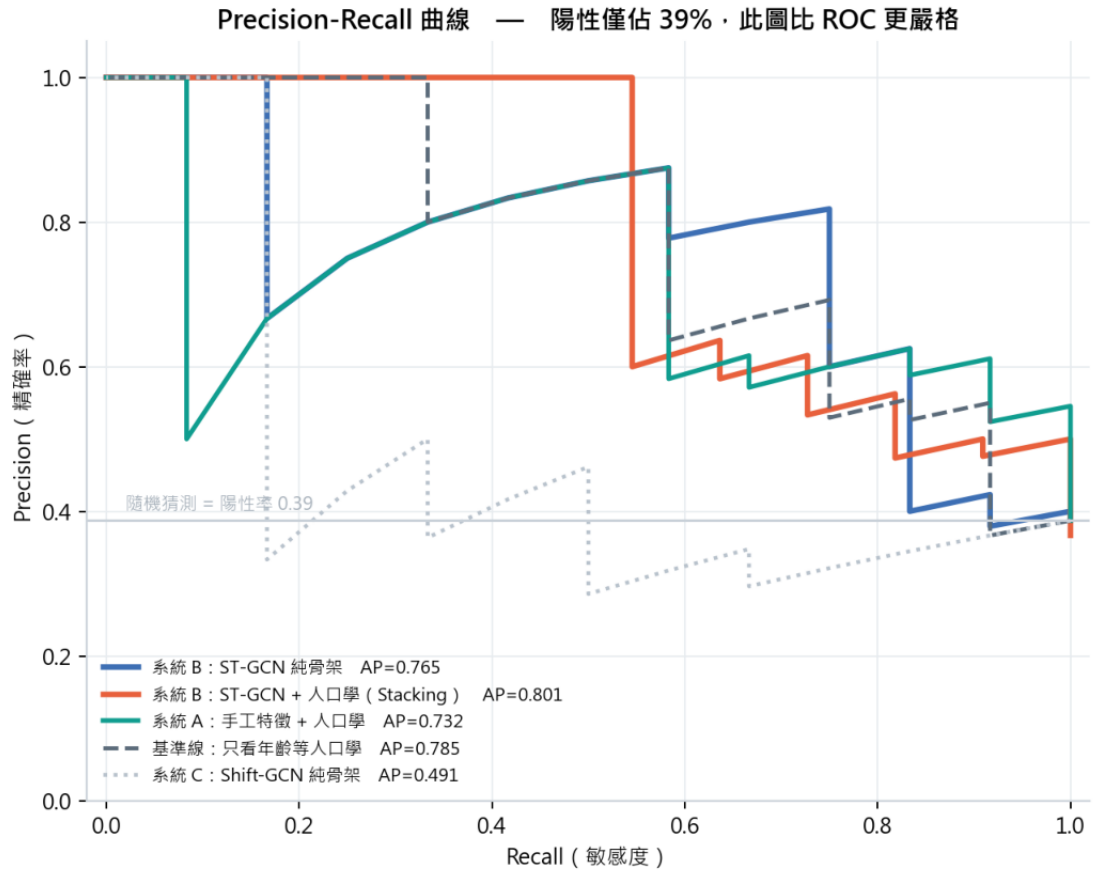
說明

曲線下的面積即為 AUC。曲線越靠左上角，代表在相同誤報率下能抓出越多真陽性。

所有曲線皆使用 out-of-fold 預測（每個人都由沒看過他的模型評估），數值與研究報告完全一致。

重點：系統 B 的純骨架版本（0.789）在完全不使用年齡的情況下，已與「只看年齡」的基準線（0.794）相當。

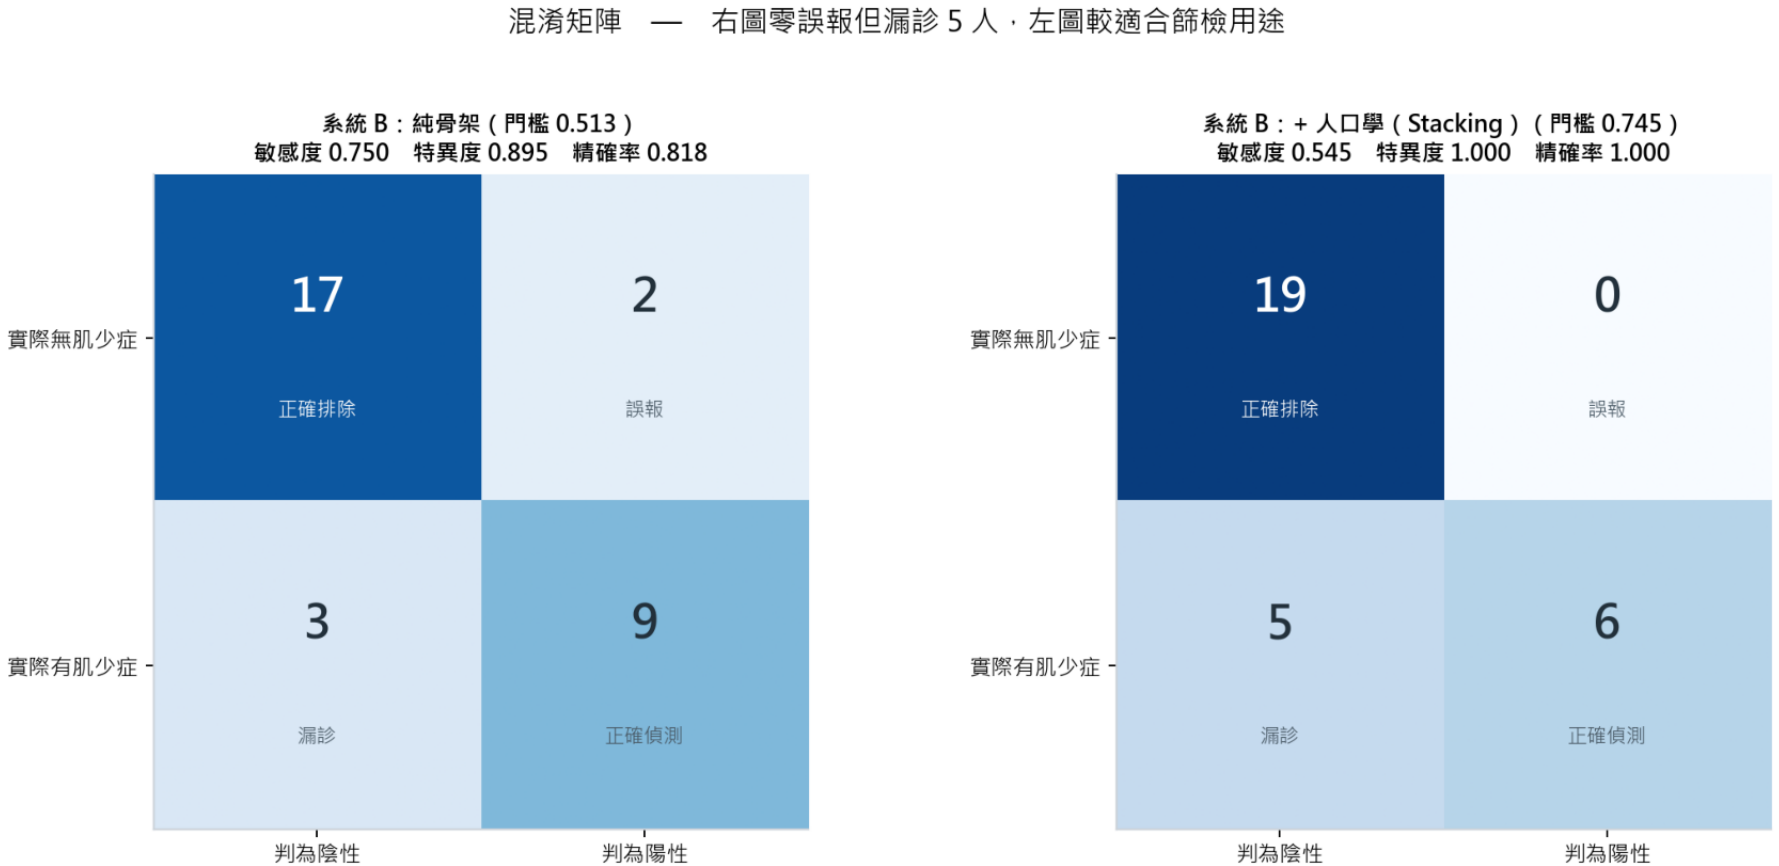
圖 13　Precision-Recall 曲線



說明

陽性個案僅佔 39%，屬於類別不平衡的情境。此時 PR 曲線比 ROC 更為嚴格，可避免高估模型表現。

圖 14　混淆矩陣與門檻取捨



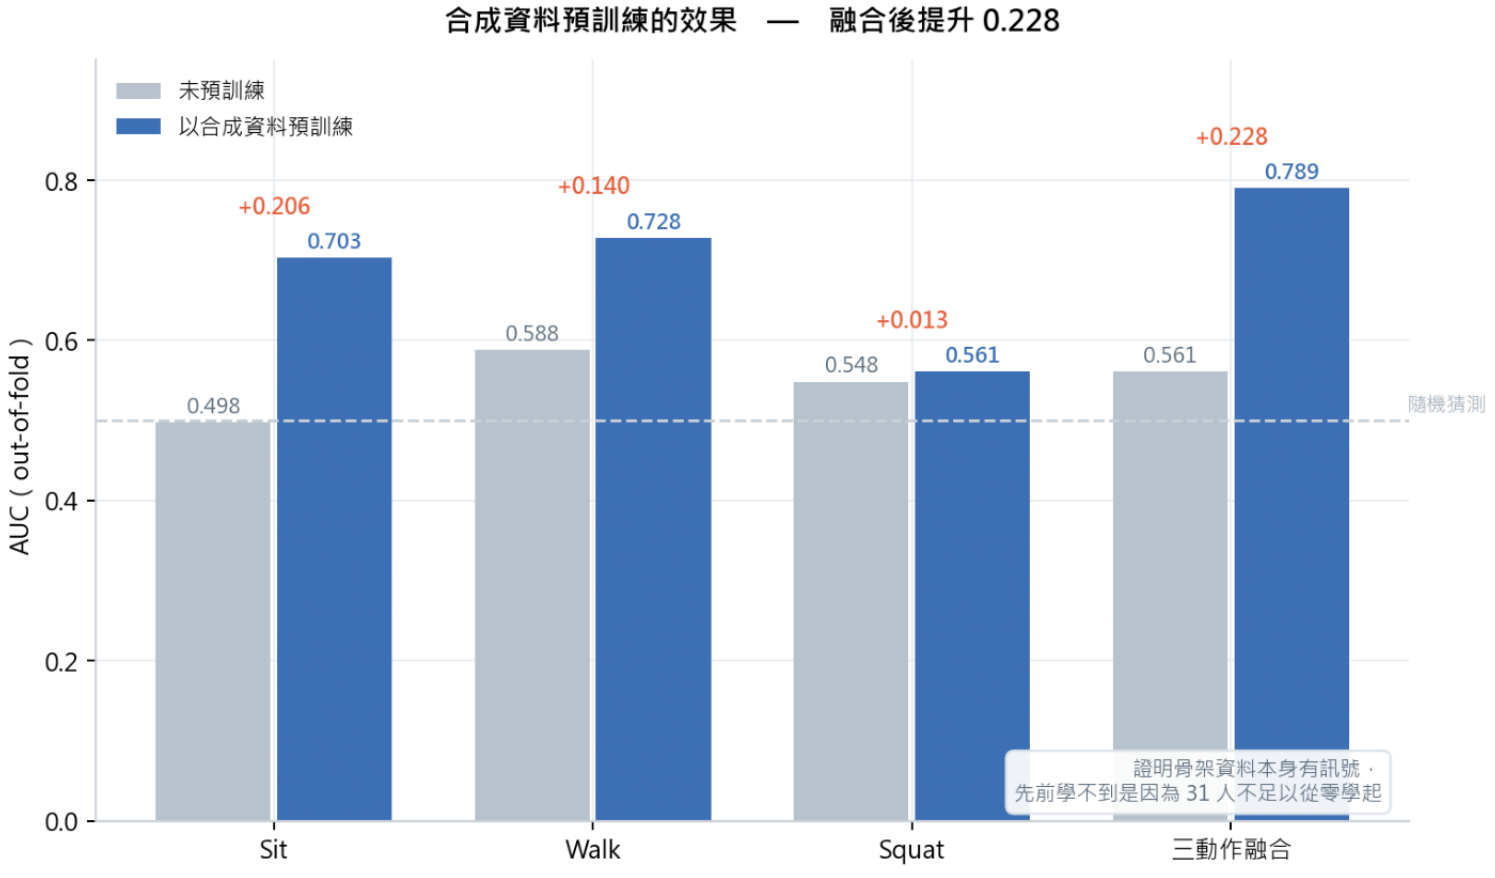
說明

左圖（純骨架）：抓出 9 位陽性、誤報 2 位、漏診 3 位。
右圖（加入年齡）：零誤報，但漏診增加到 5 位。

AUC 較高的設定，反而漏診較多。

篩檢工具通常寧可誤報也不能漏診，因此左圖的設定在臨床上較為適用。最終門檻應由臨床端依可接受的漏診率決定，而非取 AUC 最高者。

圖 15　合成資料預訓練的效果

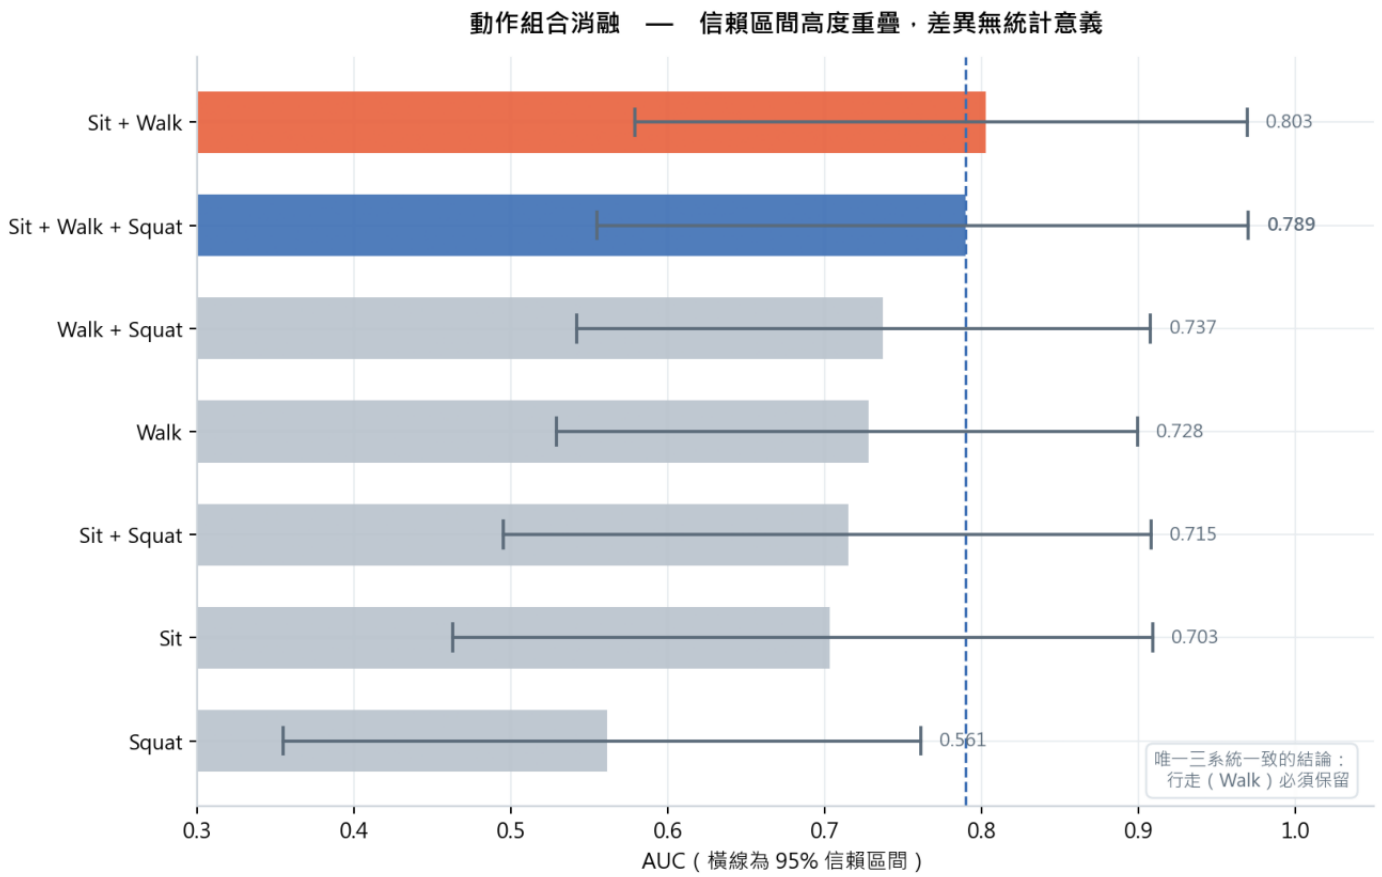


說明

31 位真實個案不足以讓深度模型從零學起。先以 58 位模擬個案預訓練（僅使用骨架，不使用其年齡等欄位），再以真實個案微調後，純骨架的判別力由 0.561 提升至 0.789。

這是本研究最主要的發現：骨架資料本身確實帶有訊號，先前學不到並非方法有誤，而是樣本量不足。

圖 16　動作組合消融



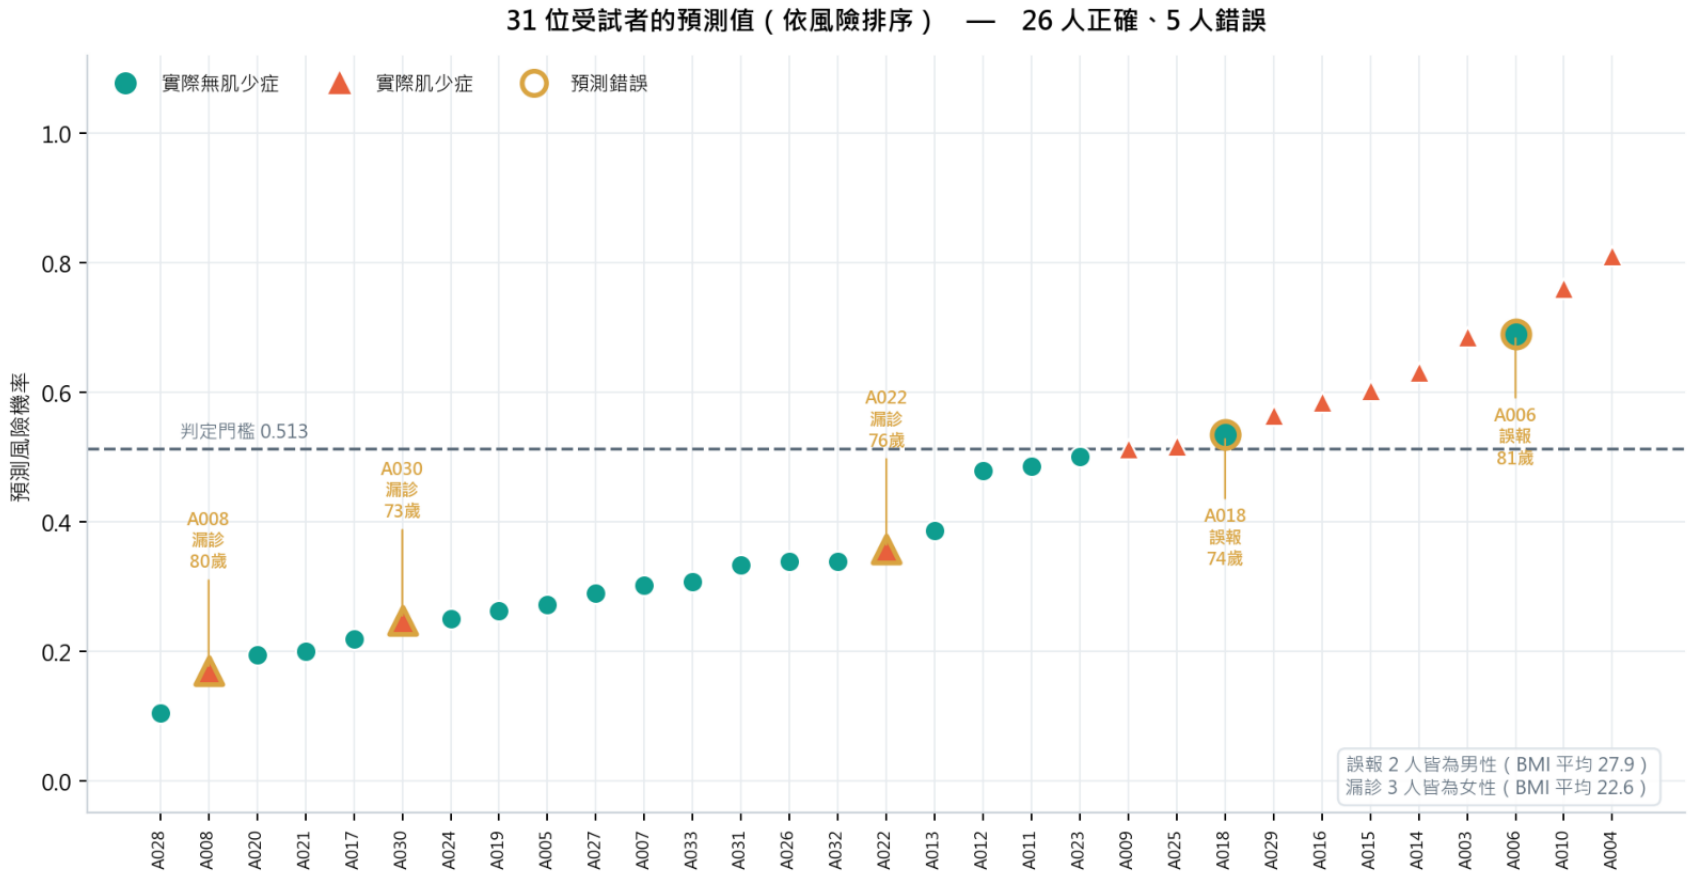
說明

回答「只能做兩項動作時該做哪兩項」。

橫線為 95% 信賴區間。各組合的區間高度重疊，代表在 31 人的樣本量下，這些差距沒有統計意義。

目前唯一能確定的是：行走必須保留。

圖 17　逐人預測與錯誤案例



說明

31 人中 26 人判斷正確、5 人錯誤。

錯誤呈現兩個值得注意的趨勢：

- 誤報的 2 人皆為男性、體型較壯（BMI 平均 27.9）
- 漏診的 3 人皆為女性、體型偏瘦（BMI 平均 22.6）

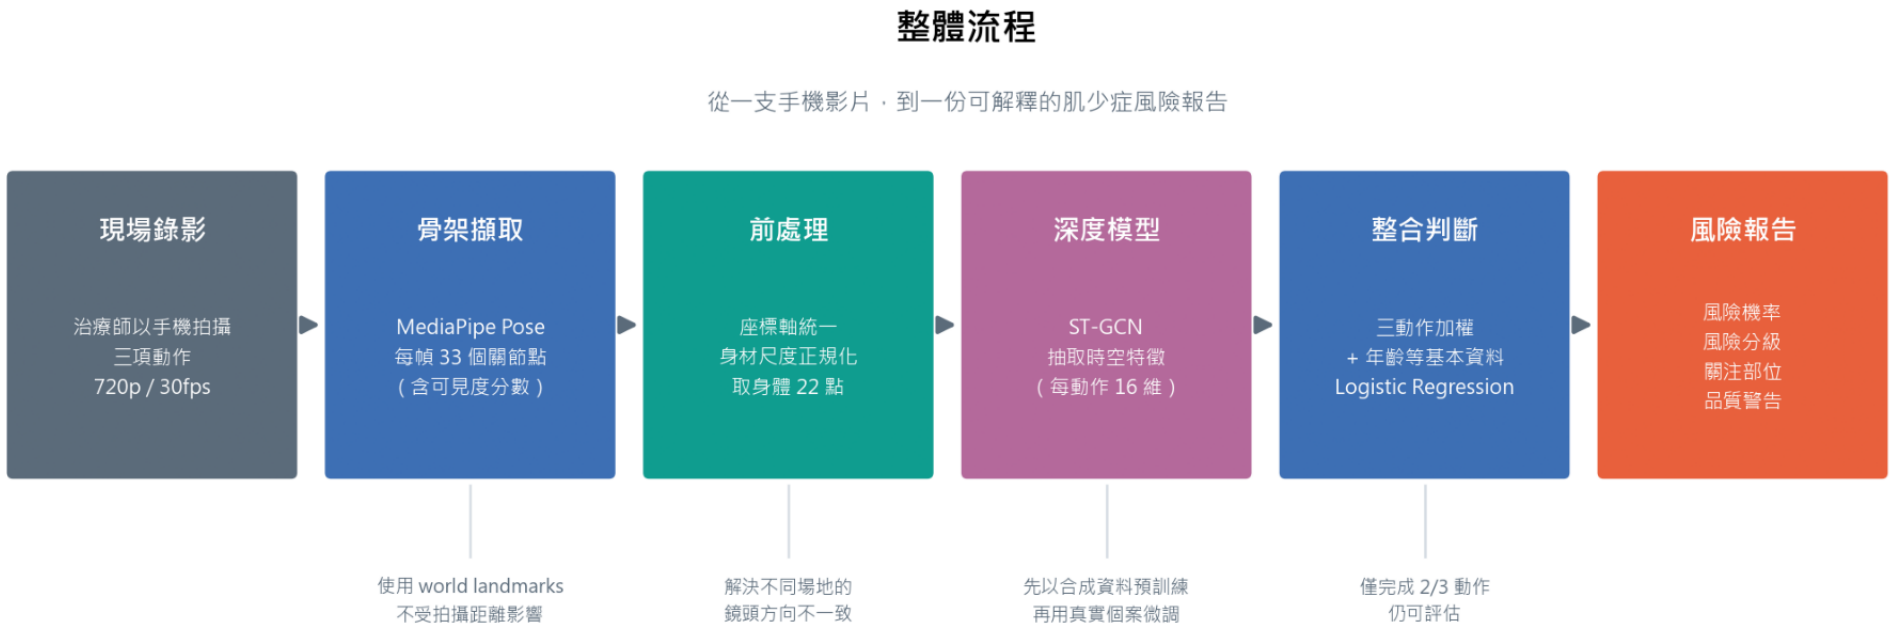
若此趨勢屬實則為危險偏誤——瘦小的長者正是肌少症的高風險族群。樣本數過少尚無法斷定，但方向值得後續追蹤。

三位漏診者的動作機率全面偏低，推測為症狀較輕的早期個案，或是「動作尚可但握力已下降」的類型（握力為模型無法取得的資訊）。

四、總結

整體流程與必須誠實說明的限制

圖 18　系統整體流程

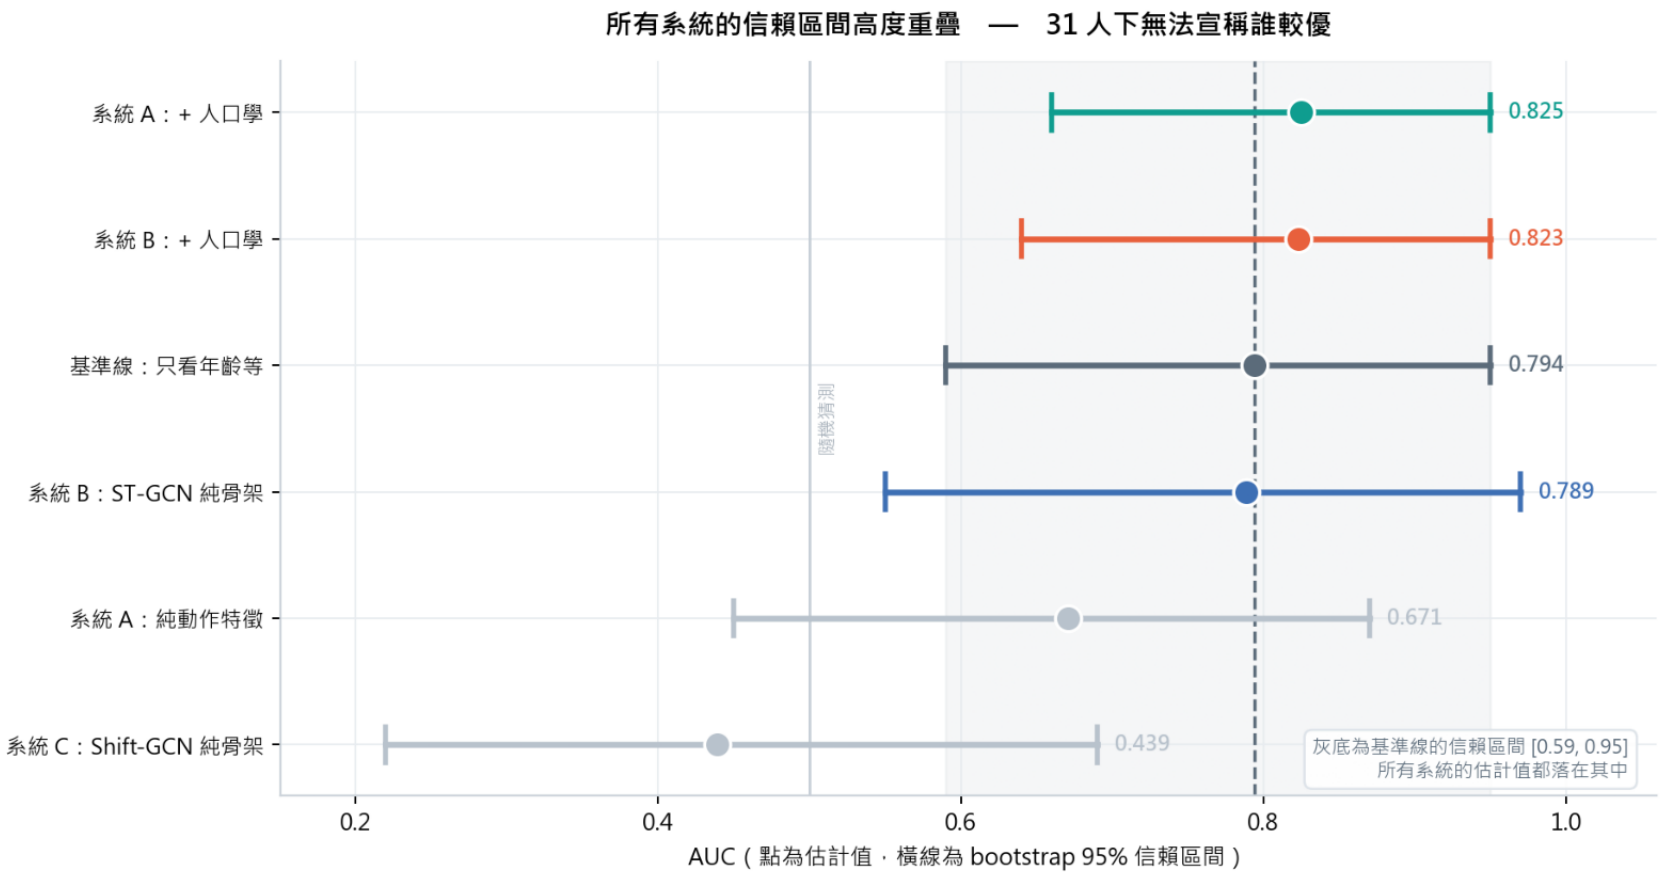


說明

從一支手機影片，到一份可解釋的風險報告，共六個階段。

下方標註了四個關鍵的設計決定，包括為何使用 world landmarks、如何處理不同場地的鏡頭方向不一致、以及為何患者僅完成 2/3 項動作時仍可評估。

圖 19　信賴區間比較



說明

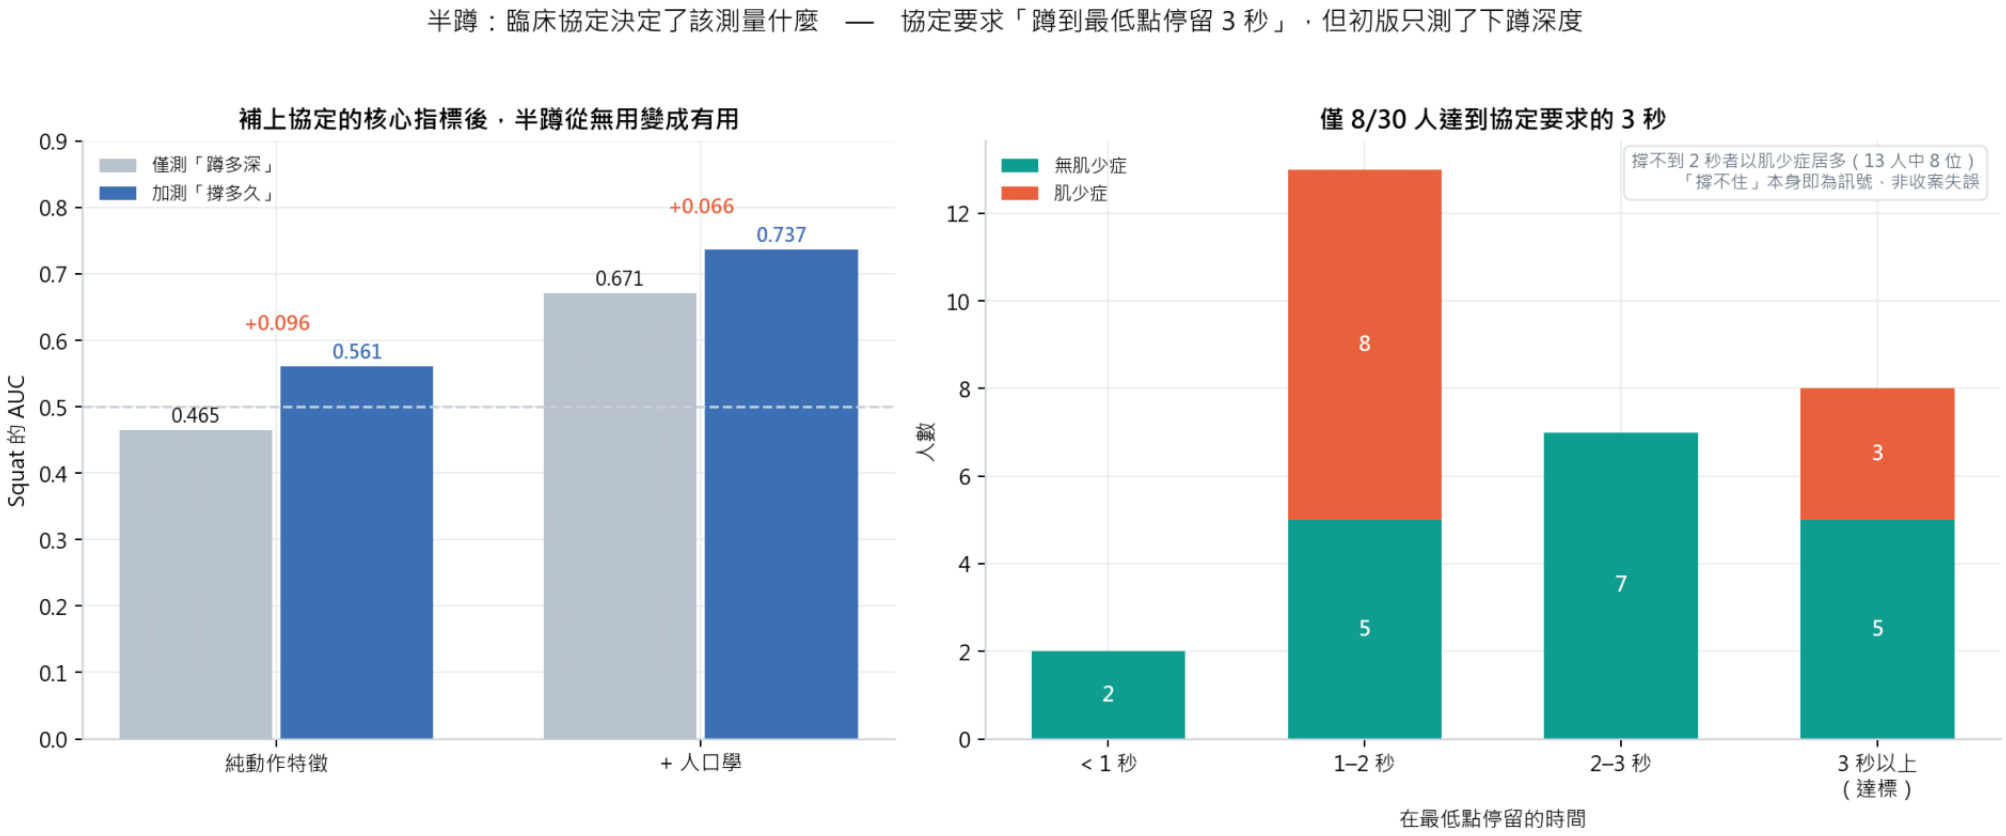
這是解讀所有結果的前提。

六個系統的 95% 信賴區間高度重疊，且所有估計值都落在基準線（只看年齡）的信賴區間 [0.59, 0.95] 之內。

以 31 人的樣本量，尚不足以宣稱任何模型優於「只看年齡」。本研究屬於可行性研究等級，證明方向可行，但非經臨床驗證的醫療器材。

信賴區間會隨樣本數增加而收窄，是最直接的進度指標。

圖 20　半蹲：臨床協定決定了該測量什麼



說明

初版的半蹲特徵只測量「蹲多深」，模型判別力僅 0.465（低於隨機），當時的結論是建議移除此動作。

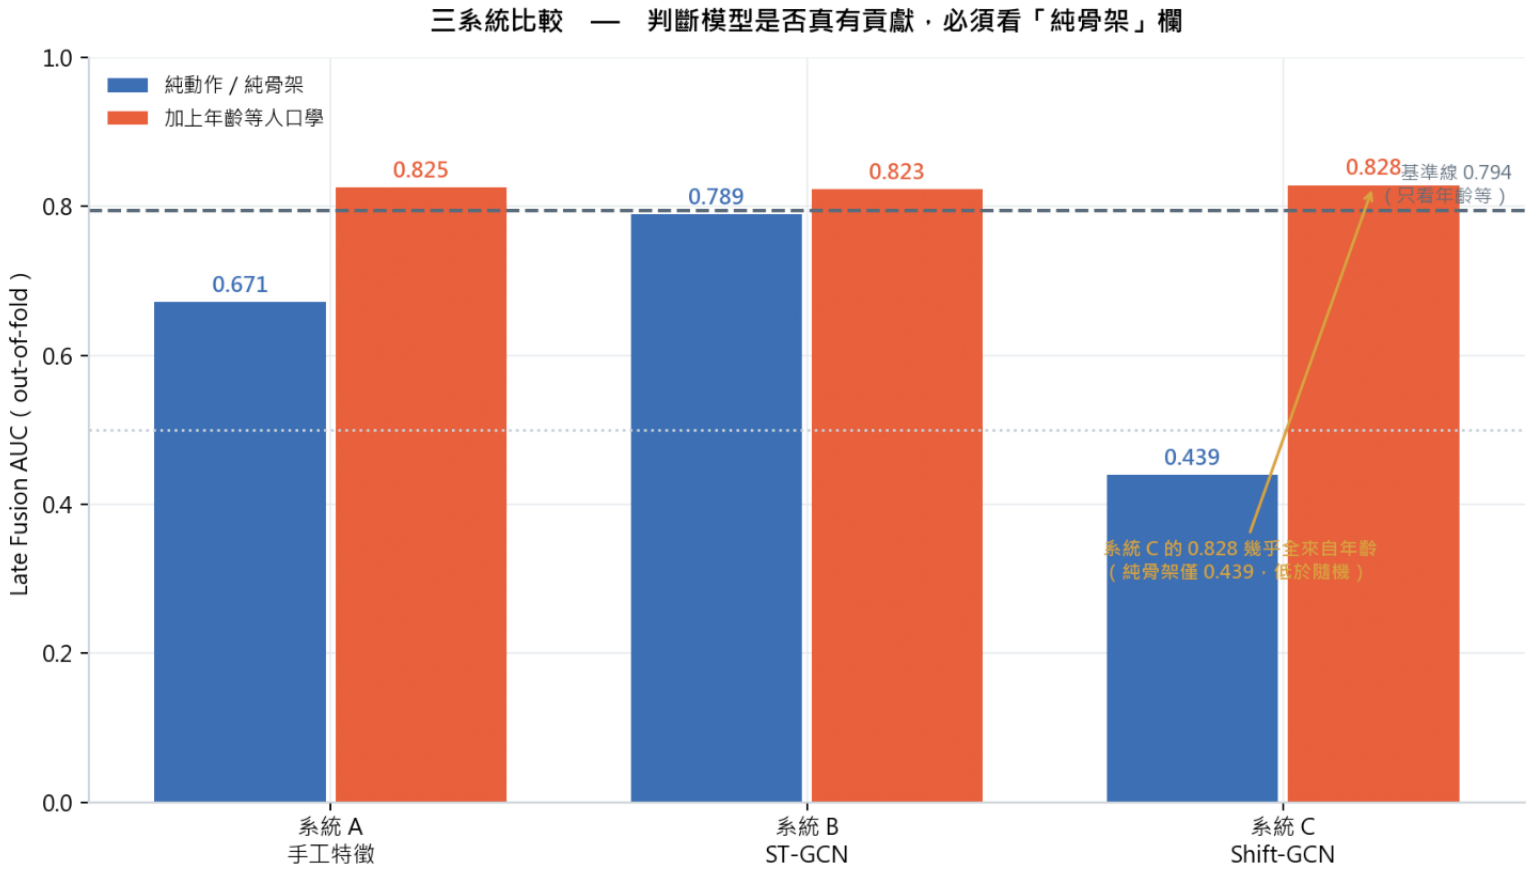
向物理治療師確認後才得知，協定的核心是「蹲到最低點停留約 3 秒」——若不要求停留時間，長者容易蹲下即刻起身或反覆快速上下，兩者皆有跌倒風險。

補上維持期的特徵後，判別力提升至 0.737，先前的移除建議因此撤回。

若當初僅依模型分數就移除半蹲，將永久失去一個具臨床價值的檢測項目。這說明 AI 無法取代臨床知識，兩者必須並行。

另外，僅 8/30 人達到協定要求的 3 秒。但撐不到 2 秒者以肌少症居多（13 人中 8 位），代表「撐不住」本身即為有效訊號，並非收案失誤。

圖 21　三系統比較



說明

判斷模型是否真有貢獻，必須看「純骨架」欄。

系統 C（Shift-GCN）的合併分數 0.828 看似最高，但其純骨架表現僅 0.439（低於隨機猜測），代表這個分數幾乎完全來自年齡，圖神經網路沒有實質貢獻。

若只比較合併欄位，會得出「Shift-GCN 最好」的錯誤結論。

解讀本報告時的三項提醒

一、圖 09 的分離程度不代表判別能力

該圖使用以全部 31 位個案訓練的最終模型，特徵帶有記憶成分。模型「看過」這些人，分得開是理所當然。
若要說明真實效能，請引用圖 12 的 ROC 曲線（out-of-fold）。

二、圖 19 是解讀所有結果的前提

31 人的樣本量下，各系統的 95% 信賴區間高度重疊，且都涵蓋「只看年齡」的基準線 0.794。
本研究不足以宣稱任何模型優於單看年齡，屬可行性研究等級。

三、AUC 高不等於臨床上好用

見圖 14：AUC 最高的設定雖然零誤報，卻漏診 5 位（共 12 位陽性）。
篩檢工具通常寧可誤報也不能漏診，最終門檻應由臨床端決定。